

§3 正态记分检验

设 $(X_1, X_2, X_3, \dots, X_m)$ 和 $(Y_1, Y_2, \dots, Y_n)$ 分别为两个连续总体 F_x 和 F_y 中随机抽取出来的样本，我们关心两个总体是否有相同的分布形状，或者他们的中位数是否相等。

将样本混合，并按升序排列，并计算 $i/(m+n+1)$ 的百分位点（正态记分），有

$$T = \sum_{i=1}^N \Phi^{-1}\left(\frac{i}{m+n+1}\right) I(\text{某个样本的观测值})$$

在原假设成立的条件下 T 的期望值为 0，即 $E(T)=0$ 。

$$\text{又因为: } \text{Var}(T) = \frac{1}{N-1} \sum_{i=1}^N (c_i - \bar{c})^2 \sum_{i=1}^N (a(i) - \bar{a})^2$$

$$\text{Var}(T) = \frac{1}{N-1} \sum_{i=1}^N (c_i - \bar{c})^2 \sum_{i=1}^N (a(i))^2$$

$$c_i (i=1, 2, \dots, m) = 1$$

$$c_i (i=m+1, m+2, \dots, m+n) = 0$$

$$\bar{c} = \frac{m}{N}$$

$$\sum_{i=1}^N (c_i - \bar{c})^2 = m(1 - \frac{m}{N})^2 + n(0 - \frac{m}{N})^2 = m(\frac{n}{N})^2 + n(\frac{m}{N})^2 = \frac{mn}{N}$$

$$S^2 = \text{Var}(T) = \frac{nm}{(m+n)(n+m-1)} \sum_{i=1}^N (a(i))^2$$

GDP	组别	排序	百分数	百分位点
15044.00	1.00	29.00	.94	1.52
12270.00	1.00	28.00	.90	1.30
5345.00	1.00	19.00	.61	.29
7730.00	1.00	23.00	.74	.65
22275.00	1.00	30.00	.97	1.85
8447.00	1.00	25.00	.81	.86
9455.00	1.00	26.00	.84	.99
8136.00	1.00	24.00	.77	.75
6834.00	1.00	22.00	.71	.55
9513.00	1.00	27.00	.87	1.13
4081.00	1.00	12.00	.39	-.29
5500.00	1.00	20.00	.65	.37

5163.00	2.00	17.00	.55	.12
4220.00	2.00	14.00	.45	-.12
4259.00	2.00	15.00	.48	-.04
6468.00	2.00	21.00	.68	.46
3881.00	2.00	10.00	.32	-.46
3715.00	2.00	5.50	.18	-.93
4032.00	2.00	11.00	.35	-.37
5122.00	2.00	16.00	.52	.04
4130.00	2.00	13.00	.42	-.20
3763.00	2.00	9.00	.29	-.55
2093.00	2.00	1.00	.03	-1.85
3715.00	2.00	5.50	.18	-.93
2732.00	2.00	2.00	.06	-1.52
3313.00	2.00	4.00	.13	-1.13
2901.00	2.00	3.00	.10	-1.30
3748.00	2.00	8.00	.26	-.65
3731.00	2.00	7.00	.23	-.75
5167.00	2.00	18.00	.58	.20

X 组的正态得分 9.97，Y 组的正态得分-9.98，两组的正态得分的平方和为 24.013

第二步：计算某一个样本正态记分和 T 与所有样本的正态记分平方和 $\sum_{i=1}^N s_i^2$ ，构造统计量：

$$Z = \frac{T}{S}$$

$$\text{其中 } S^2 = \frac{mn \sum_{i=1}^N s_i^2}{(m+n-1)(m+n)}$$

$$Z = \frac{T}{S} = 9.97 / 2.46 = 4.05 = 9.97 / 2.46 = 4.05$$

$$P = p(Z > 4.05) = 2.5622 * 10^{-5}$$

两独立样本的 Siegel-Tukey 方差检验

假定有两独立样本

$$X_1, X_2, \dots, X_m \sim F\left(\frac{x - \theta_1}{\sigma_1}\right)$$

$$\text{和 } Y_1, Y_2, \dots, Y_n \sim F\left(\frac{x - \theta_2}{\sigma_2}\right)。$$

这里假定 $F(\cdot)$ 为连续函数，而且以 Y 轴为对称，且 $\theta_1 = \theta_2$ 。

检验的假设：

H_0 : 样本来自同一总体分布

H_1 : 样本来自同一总体分布仅仅方差不同。

顺序统计量	$X_{(1)}$	$X_{(2)}$	$X_{(3)}$	---	$X_{(n-3)}$	$X_{(n-2)}$	$X_{(n-1)}$	$X_{(n)}$
秩	1	4	5	---	7	6	3	2

如果一个总体方差比较大，那么它的最大值和最小值之间的差异会比较大。如果两个总体的标志变动度的比较，两个总体的样本混合排序以后，分散程度大的总体的样本可能会排在首尾，可能的秩和较小，而分散程度教小的可能排在中位数左右，所以

$$W_y = W_{xy} + \frac{n(n+1)}{2} \text{ 或 } W_{xy} = W_y + \frac{n(n+1)}{2}$$

$$W_x = W_{yx} + \frac{m(m+1)}{2} \text{ 或 } W_{yx} = W_x + \frac{m(m+1)}{2}$$

根据前面的结论

$$\begin{cases} E(W_{yx}) = \sum_i^m \sum_j^n E[I(X_i > Y_j)] = \sum_{i=1}^m \sum_{j=1}^n \frac{1}{2} = \frac{mn}{2} \\ \text{Var}(W_{yx}) = \text{Var}\left\{\sum_i^m \sum_j^n E[I(X_i > Y_j)]\right\} = \frac{mn(N+1)}{12} \end{cases}$$

或

$$\begin{cases} E(W_x) = \sum_i^m \sum_j^n E[I(X_i > Y_j)] = \sum_{i=1}^m \sum_{j=1}^n \frac{1}{2} = \frac{m(N+1)}{2} \\ \text{Var}(W_{yx}) = \text{Var}\left\{\sum_i^m \sum_j^n E[I(X_i > Y_j)]\right\} = \frac{mn(N+1)}{12} \end{cases}$$

人均 GDP	地区类别	修正人均 GDP	秩
22275	1	22275	2

15044	1	15044	3
12270	1	12270	6
6468	2	10829.5	7
5167	2	9528.5	10
5163	2	9524.5	11
9513	1	9513	14
5122	2	9483.5	15
9455	1	9455	18
4259	2	8620.5	19
4220	2	8581.5	22
4130	2	8491.5	23
8447	1	8447	26
4032	2	8393.5	27
3881	2	8242.5	30
8136	1	8136	29
3763	2	8124.5	28
3748	2	8109.5	25
3731	2	8092.5	24
3715	2	8076.5	21
3715	2	8076.5	20
7730	1	7730	17
3313	2	7674.5	16
2901	2	7262.5	13
2732	2	7093.5	12
6834	1	6834	9
2093	2	6454.5	8
5500	1	5500	5
5345	1	5345	4
4081	1	4081	1

$$Z = \frac{W_x - m(N+1)/2}{\sqrt{mn(N+1)/12}} \sim N(0,1)$$

$$Z = \frac{134 - 31 \times 12 / 2}{\sqrt{12 \times 18 \times (30+1)/12}} = \frac{-52}{23.62} = -2.20$$

$$P(Z < -2.20) = 0.013903$$

可见沿海地区人均 GDP 的方差显著性偏大。

注：当量总体的位置参数不等时，要求出两个总体的位置参数差，然后在位置参数较小的观测值均加上参数差，然后再进行分析。

两样本尺度的平方秩检验

方差的定义是假定独立同分布的样本 $X_1, X_2, \dots, X_m \sim F(\frac{x-\theta_1}{\sigma_1})$;

$Y_1, Y_2, \dots, Y_n \sim F(\frac{y-\theta_2}{\sigma_2})$, 这里 $F(\cdot)$ 为连续的分布函数。假定两个总体的位置参数是相等, 即

$$\theta_1 = \theta_2。$$

1、检验的假设

$$H_0 : \sigma_1 = \sigma_2 ; H_0 : \sigma_1 \neq \sigma_2$$

2、统计量

为了对上面的假设做出检验, 我们首先将两个总体的样本分别求混合后排序, 得两样本的秩再平方, 分别记为

$$\text{总体 X: } R_{11}, R_{12}, R_{13}, \dots, R_{1m}$$

$$\text{总体 Y: } R_{21}, R_{22}, R_{23}, \dots, R_{2n}$$

$$T_x = \sum_{i=1}^m R_{1i} = \sum_{i=1}^N R_i I(\text{属于 X 的样本})$$

$$T_y = \sum_{i=1}^n R_{2i} = \sum_{i=1}^N R_i I(\text{属于 Y 的样本})$$

$$\bar{R} = \frac{1}{m+n} \sum_{i=1}^{m+n} R_i$$

$$\text{而方差为: } S^2 = \frac{mn \left\{ \sum_{i=1}^k R_i^2 - (m+n)(\bar{R}^2) \right\}}{(m+n)(m+n-1)}$$

$$Z_x = \frac{T_x - m\bar{R}}{S} \text{ 或 } Z_y = \frac{T_y - n\bar{R}}{S} \text{ 渐近标准正态分布。}$$

页数	类别 (1) 为数学	与平均数 的差	差的绝对值	秩	平方秩 R_i
95	2	0.3	0.3	1	1
94	2	-0.7	0.7	2	4
94	2	-0.7	0.7	3	9
96	2	1.3	1.3	4	16
93	2	-1.7	1.7	5	25
98	2	3.3	3.3	6	36
91	2	-3.7	3.7	7	49
91	2	-3.7	3.7	8	64
91	2	-3.7	3.7	9	81
87	1	4.05	4.05	10	100
87	1	4.05	4.05	11	121
99	2	4.3	4.3	12	144
99	2	4.3	4.3	13	169
99	2	4.3	4.3	14	196
90	2	-4.7	4.7	15	225
88	1	5.05	5.05	16	256
100	2	5.3	5.3	17	289
100	2	5.3	5.3	18	324
88	2	-6.7	6.7	19	361
76	1	-6.95	6.95	20	400
90	1	7.05	7.05	21	441
102	2	7.3	7.3	22	484
75	1	-7.95	7.95	23	529
85	2	-9.7	9.7	24	576
93	1	10.05	10.05	25	625
72	1	-10.95	10.95	26	676
94	1	11.05	11.05	27	729
96	1	13.05	13.05	28	784

68	1	-14.95	14.95	29	841
98	1	15.05	15.05	30	900
110	2	15.3	15.3	31	961
79	2	-15.7	15.7	32	1024
65	1	-17.95	17.95	33	1089
65	1	-17.95	17.95	34	1156
64	1	-18.95	18.95	35	1225
63	1	-19.95	19.95	36	1296
105	1	22.05	22.05	37	1369
105	1	22.05	22.05	38	1444
56	1	-26.95	26.95	39	1521
112	1	29.05	29.05	40	1600

$$T_x=17103 \quad T_y=5037 \quad \bar{R} = 553.5 \quad n_x=20 \quad n_y=20$$

$$S^2 = \frac{mn \left\{ \sum_{i=1}^k R_i^2 - (m+n)(\bar{R}^2) \right\}}{(m+n)(m+n-1)}$$

$$S^2 = \frac{20 \times 20 \{ 21781332 - 40 \times (553.5^2) \}}{40 \times 39} = 2442780$$

$$S=1562.94$$

$$Z = \frac{17103 - 20 \times 553.5}{1562.94} = 3.86$$

数学在页数上的差异比经济博士论文在页数上的差异大。